PROJETO DE SISTEMAS BASEADOS EM APRENDIZAGEM DE MÁQUINA · UFRN

RAG avançado: como buscar melhor

Baseline × semantic chunking, parent-child e hybrid RRF (família F2, *How to Search*) sobre normas acadêmicas da UFRN

6
normas no corpus

20
perguntas com gabarito

6
experimentos: baseline ×3 e 3 técnicas

Repositório: **github.com/felipeafigueiredo/advanced_rag**

CONTEXTO, PROBLEMA E OBJETIVO

Busca avançada em RAG: o problema e o que queremos medir

Contexto

RAG recupera trechos de documentos e os entrega a um LLM para responder com base neles.

O corpus são normas acadêmicas da UFRN, com artigos, prazos, percentuais e remissões entre normas.

Problema

O RAG tradicional (chunks de tamanho fixo + busca por embeddings) corta trechos de forma arbitrária.

Ele tende a falhar em termos exatos (nº de artigo, prazo, sigla) e quando a resposta está espalhada por vários trechos ou documentos.

Objetivo

Testar se técnicas de busca avançada da família F2 (*How to Search*) melhoram a resposta em relação ao baseline.

Mesmas 20 perguntas com gabarito; comparação de acurácia, recall de documento, latência e chamadas ao LLM.

DADOS

Corpus: 6 normas da UFRN (109 páginas) e 20 perguntas com gabarito

CORPUS ESCOLHIDO

DOCUMENTO	ASSUNTO	PÁGS.
Resolução 016/2023-CONSEPE	Regulamento dos Cursos de Graduação	82
Resolução 013/2022-CONSEPE	Reocupação de vagas residuais	9
IN 8/2023	Depósito do TCC de graduação	7
IN 5/2022	Colação de grau individual	4
IN 10/2025	Registro de diplomas digitais	4
IN 11/2026	Revalidação de diploma estrangeiro	3

O Regulamento concentra 75% das páginas: perguntas “entre documentos” cruzam o Regulamento com uma IN ou resolução.

20 PERGUNTAS, 4 TIPOS

6
Multi-chunk

5
Simples

5
Entre documentos

4
Termo exato

Cada pergunta tem resposta de referência (gabarito) e o(s) artigo(s) de origem. A lista completa está no próximo slide.

DADOS

As 20 perguntas do experimento

1 Termo exato Qual é a carga horária mínima de componentes curriculares optativos em uma estrutura curricular da UFRN?

2 Termo exato Quais são os limites mínimo e máximo da carga horária complementar de uma estrutura curricular?

3 Multi-chunk O estudante que não cumprir os 10% de carga horária de extensão pode concluir o curso?

4 Multi-chunk Qual é a diferença entre cancelamento de matrícula e trancamento de matrícula em um componente curricular?

5 Simples O que são vagas residuais e qual situação é expressamente excluída dessa definição?

6 Simples Um estudante com vínculo ativo em curso de graduação da UFRN pode concorrer a vaga residual no mesmo curso?

7 Termo exato Quais notas mínimas no ENEM evitam a eliminação no processo seletivo de reocupação de vagas residuais?

8 Multi-chunk Para um curso da área Tecnológica II, qual é o peso da prova de Matemática do ENEM e como a nota do ENEM entra na nota final da seleção de reocupação de vagas residuais?

9 Simples Qual é o prazo máximo de embargo de um TCC e quem o define?

10 Simples A conclusão do fluxo de depósito do TCC é necessária para colar grau?

11 Simples A quem se aplica a revalidação de diploma regulamentada pela IN 11/2026?

12 Multi-chunk Como a documentação para a revalidação de diploma estrangeiro (REVALIDA) deve ser entregue e qual é o prazo padrão de análise e registro?

13 Multi-chunk Quais são as regras do trancamento de matrícula em componente curricular quanto a prazo, número de vezes e efetivação?

14 Multi-chunk Um estudante de disciplina presencial obteve média parcial 5,5 e tem 80% de frequência. Ele é aprovado direto? Tem direito à avaliação de reposição? O que precisa obter nela para ser aprovado?

15 Entre docs Cancelamentos de curso por decurso de prazo geram vagas residuais?

16 Entre docs Quem deve depositar o TCC e até quando esse depósito precisa ser feito?

17 Entre docs Como o estudante passa a ter o status 'FORMADO' exigido para a colação de grau individual e quais são os requisitos para solicitá-la?

18 Entre docs Em que situações a colação de grau ocorre em sessão simples e quais são as formas de colação de grau individual?

19 Entre docs Um ex-estudante da UFRN que teve o vínculo cancelado por abandono de curso pode concorrer a vaga residual? Em que situação se configura o abandono?

20 Termo exato Qual é o prazo máximo para a DiRED analisar a documentação e registrar diplomas digitais expedidos por outras IES do Rio Grande do Norte, e esse prazo pode ser prorrogado?

EXPLICAÇÃO

Quatro formas de buscar: do RAG tradicional ao híbrido

RAG tradicional baseline

Chunks de 1.000 caracteres com sobreposição de 200 (285 chunks).

Busca densa por embeddings; os 6 mais similares vão ao gerador.

Rodado 3 vezes: r1, r2 e r3.

Semantic chunking

Agrupa unidades normativas (artigos e parágrafos) e corta o chunk onde a similaridade entre unidades vizinhas cai (< 0,68).

Chunks de 650 a 1.350 caracteres (209 chunks); busca densa, top-6.

Parent-child

Busca em filhos pequenos (~380 caracteres; 1.129 filhos).

Mas entrega ao LLM o trecho pai de 1.500 caracteres: precisão na busca e contexto maior na resposta.

Hybrid RRF

Combina o ranking denso (embeddings) com o ranking lexical BM25 pelo *Reciprocal Rank Fusion* (k = 2), sobre os chunks do baseline.

O BM25 favorece termos literais como artigo, prazo e sigla.

Em todos os experimentos: gerador qwen2.5:3b · embeddings nomic-embed-text · top-6 trechos · Google Colab com GPU T4.

TIPOS DE PERGUNTA

Cada tipo de pergunta testa uma fragilidade diferente da busca

Simples 5

Resposta em um único trecho. Servem de **controle**: mostram se a técnica piora algo.

Ex. (id 9): Qual é o prazo máximo de embargo de um TCC e quem o define?

Multi-chunk mesmo documento 6

Trechos longos: um artigo e seus parágrafos, ou regra geral e exceção.

Ex. (id 3): O estudante que não cumprir os 10% de carga horária de extensão pode concluir o curso?

Entre documentos 5

Junta o Regulamento com uma IN ou resolução, p. ex. a regra de colação no Regulamento e o procedimento na IN 5.

Ex. (id 17): Como o estudante passa a ter o status “FORMADO” exigido para a colação de grau individual?

Termo exato 4

A resposta depende de um número de artigo, prazo, nota ou sigla.

Ex. (id 7): Quais notas mínimas no ENEM evitam a eliminação no processo seletivo de reocupação de vagas residuais?

MÉTRICAS DE AVALIAÇÃO

Quatro métricas: uma de qualidade e três de custo e cobertura da busca

Acurácia

Percentual das 20 respostas corretas em relação ao gabarito.

Medida de duas formas (automática e manual), explicadas a seguir. Os resultados usam a **manual** como referência.

Recall de documento

Por pergunta, vale 1 se ao menos um dos documentos que contêm a resposta aparece entre os 6 trechos recuperados; 0 caso contrário. Reportado como média.

Mede se a busca achou o documento certo, não o trecho certo.

Latência

Tempo médio por pergunta, em segundos: busca + geração da resposta.

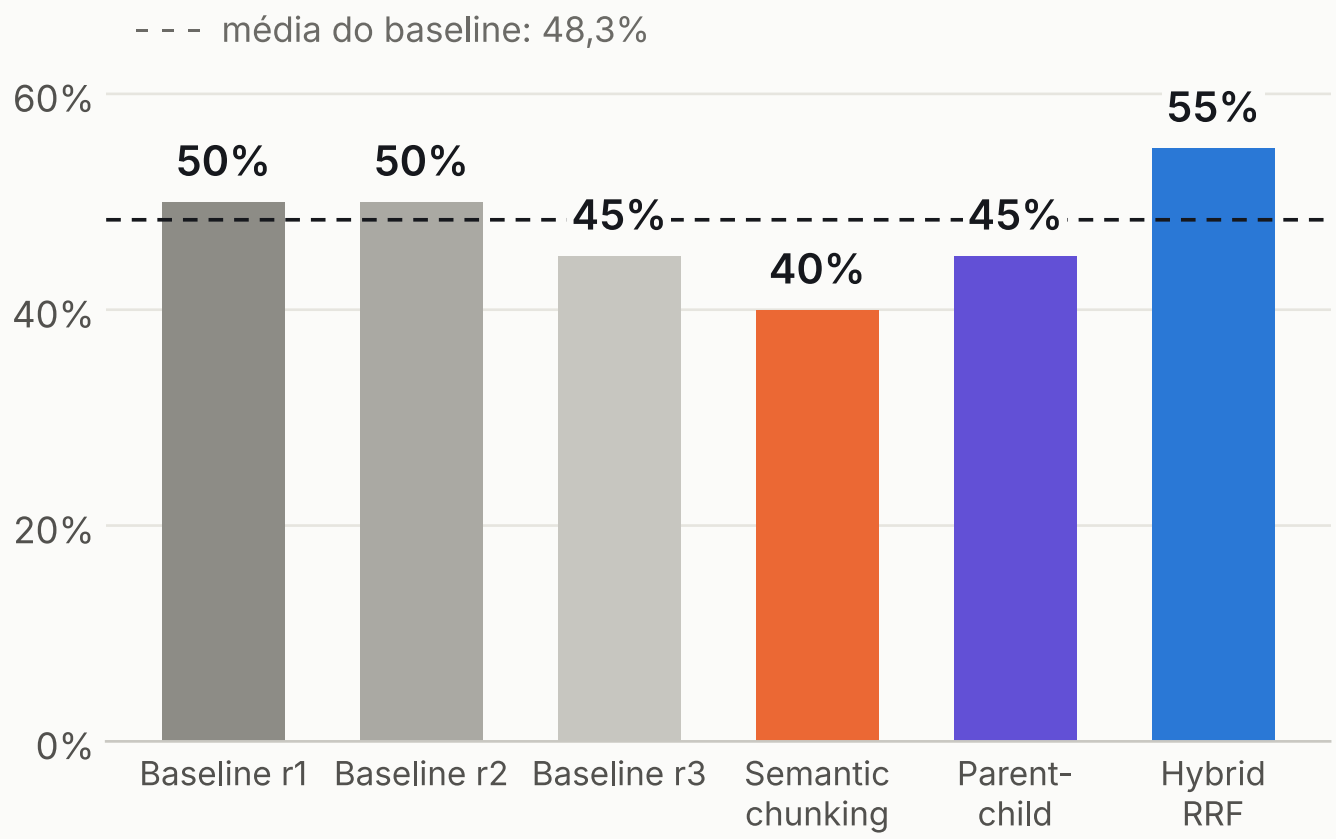
Não inclui o tempo do juiz da avaliação automática.

Chamadas ao LLM

Número de chamadas ao gerador por pergunta.

Todas as técnicas fazem 1 chamada: nenhuma usa LLM para reescrever consulta ou reordenar trechos. A chamada do juiz não é contada.

Hybrid RRF tem a maior acurácia média, mas por margem curta



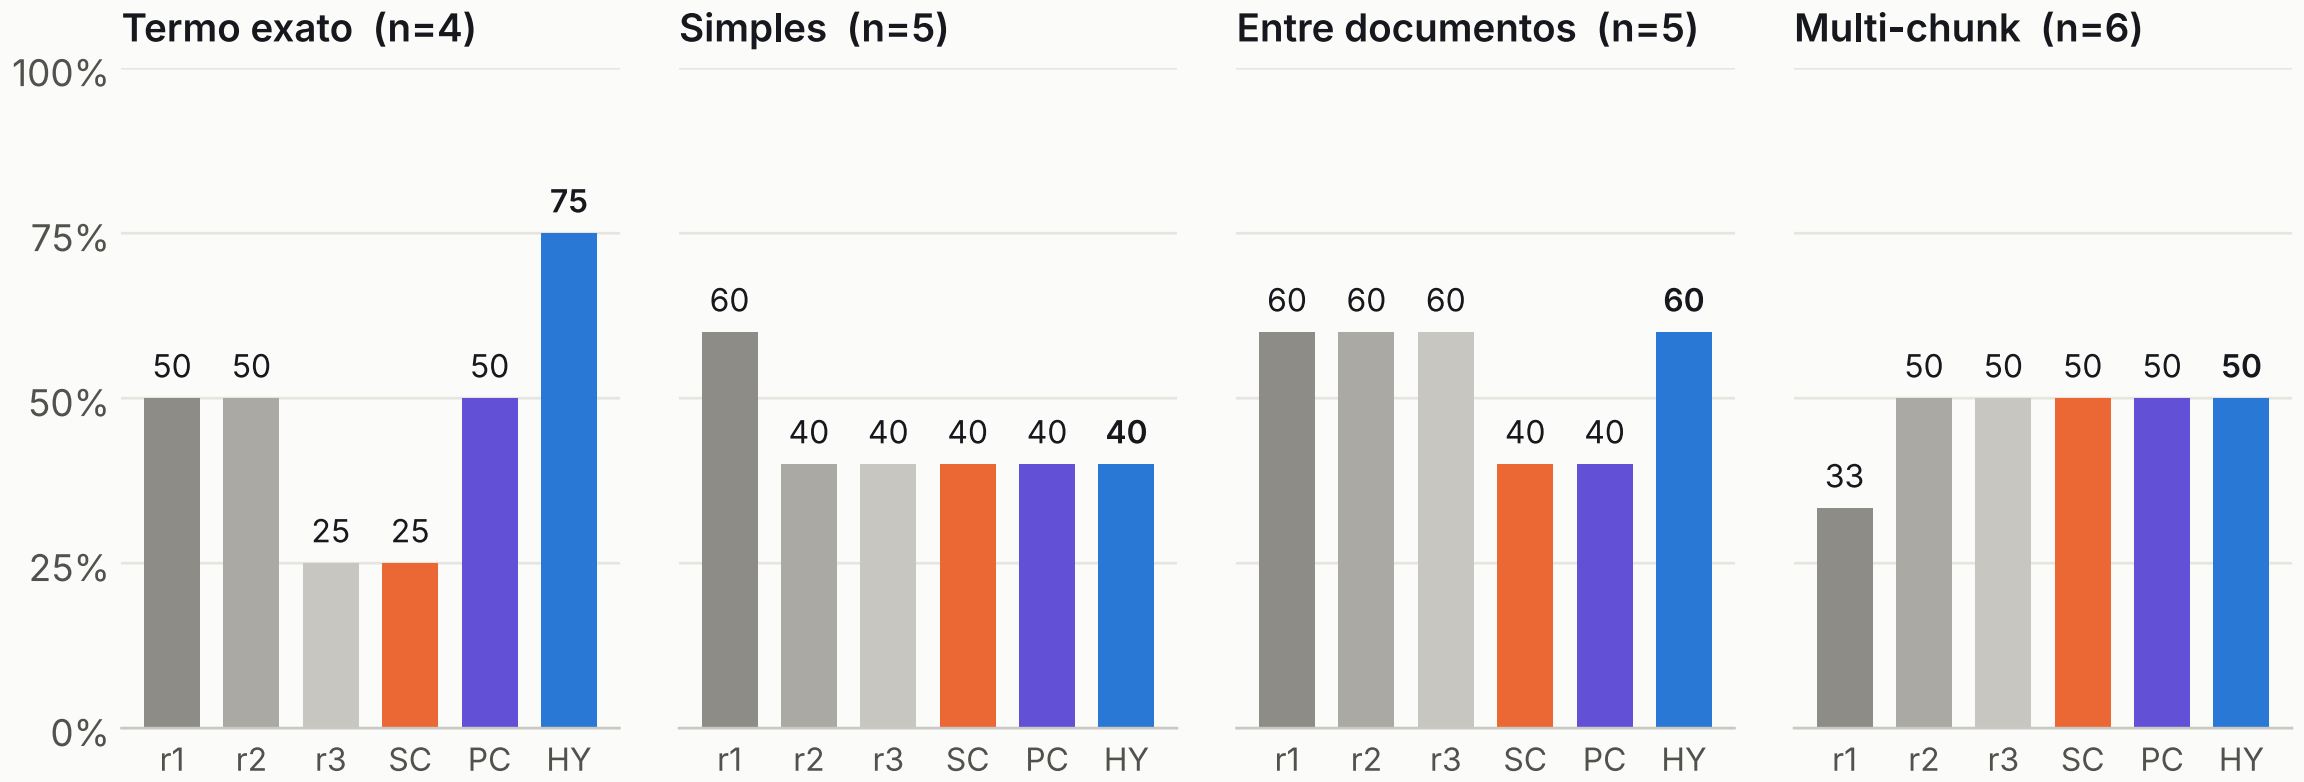
Acurácia manual (acerto_manual), 20 perguntas por experimento.

55%
Hybrid RRF (11 de 20)

48,3%
média do baseline (45% a 50% nas 3 rodadas)

- Diferença de +6,7 pp sobre a média do baseline: cerca de 1 pergunta.
- Parent-child (45%) e semantic chunking (40%) ficam dentro da faixa do baseline ou abaixo dela.
- Cada pergunta vale 5 pp.

O ganho do Hybrid RRF se concentra nas perguntas de termo exato



r1, r2, r3 = baseline · **SC** = semantic chunking · **PC** = parent-child · **HY** = hybrid RRF. Acurácia manual, em %.

Termo exato
Hybrid 75% contra 25% a 50% no baseline.

Simples (controle)
Nenhuma técnica passa de 40%; o baseline fica entre 40% e 60%.

Entre documentos
Hybrid empata com o baseline (60%); SC e PC caem para 40%.

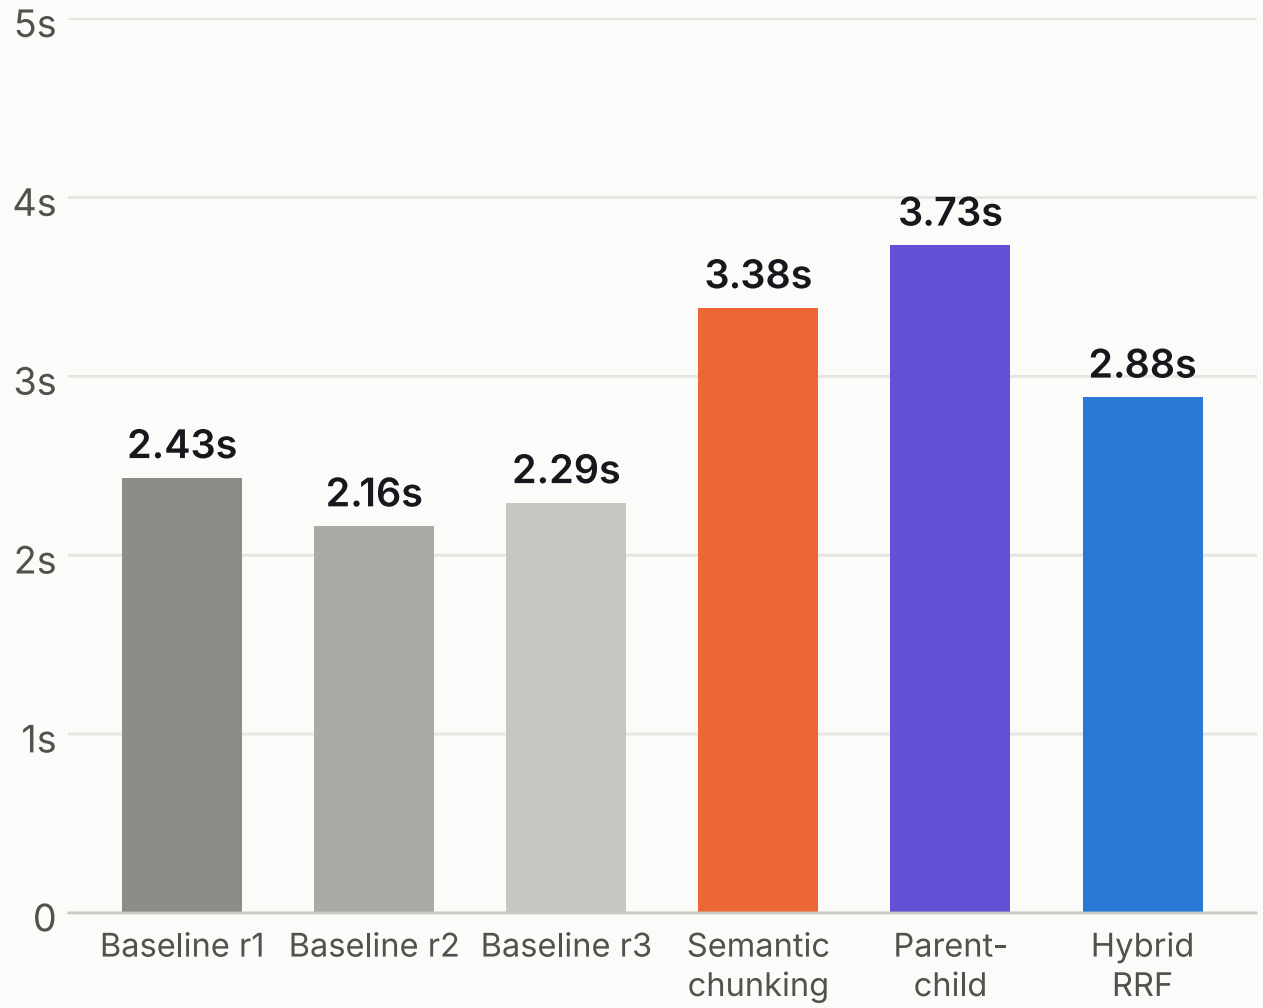
Multi-chunk
As três técnicas ficam em 50%; o baseline varia de 33% a 50%.

Recall e chamadas não diferenciam as técnicas; a diferença está na latência

100%
recall de documento nos 6 experimentos

1
chamada ao LLM por pergunta nos 6 experimentos

- A busca sempre trouxe o documento certo; o que muda é o trecho e a resposta.
- Hybrid RRF: +0,5 a +0,7 s por pergunta sobre o baseline.
- Parent-child é o mais lento (3,73 s).



Latência média por pergunta (busca + geração), em segundos.

AVALIAÇÃO AUTOMÁTICA × MANUAL

Duas formas de dar nota: um modelo-juiz e uma revisão humana cega

Automática acerto_auto

O próprio qwen2.5:3b, o mesmo modelo que gera a resposta, atua como juiz.

Recebe pergunta, gabarito e resposta e diz “sim” ou “não”: a resposta acerta números, prazos e regras centrais sem contradizer o gabarito?

Resposta vazia ou “INFORMAÇÃO AUSENTE” vira 0 direto.

Rápida e reprodutível, mas depende de um modelo pequeno.

Manual acerto_manual

Planilha cega: 120 respostas embaralhadas, sem o nome do experimento e sem a nota automática.

Critério definido antes: 1 se traz todos os elementos que a pergunta pede e não contradiz o gabarito; 0 caso contrário.

Citação de artigo incorreta não invalida a resposta.

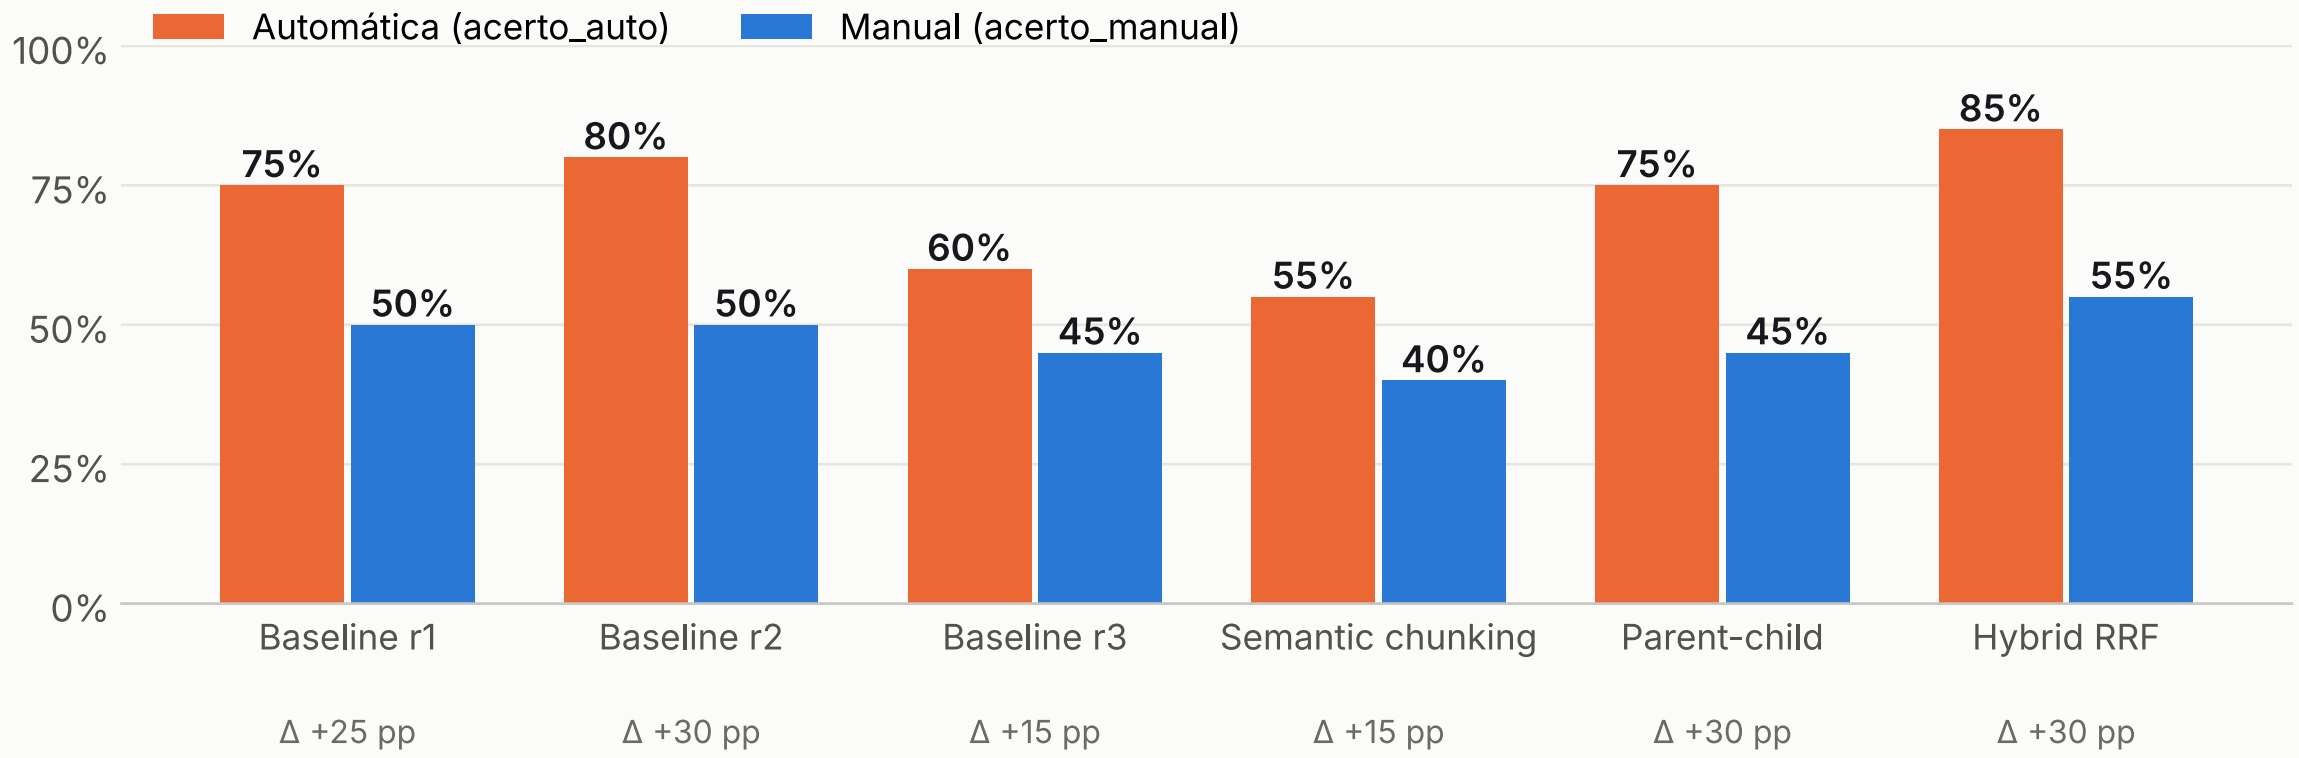
Tomada como referência.

Falso positivo
a automática deu 1 e a manual deu 0 (o juiz aprovou uma resposta errada).

Falso negativo
a automática deu 0 e a manual deu 1 (o juiz reprovou uma resposta certa).

COMPARAÇÃO: ACERTO_AUTO × ACERTO_MANUAL

A avaliação automática superestima a acurácia em todos os experimentos



Δ = acerto_auto − acerto_manual, em pontos percentuais.

86 × 57 acertos
Em 120 respostas, o juiz aprovou 71,7% e a revisão manual 47,5%.

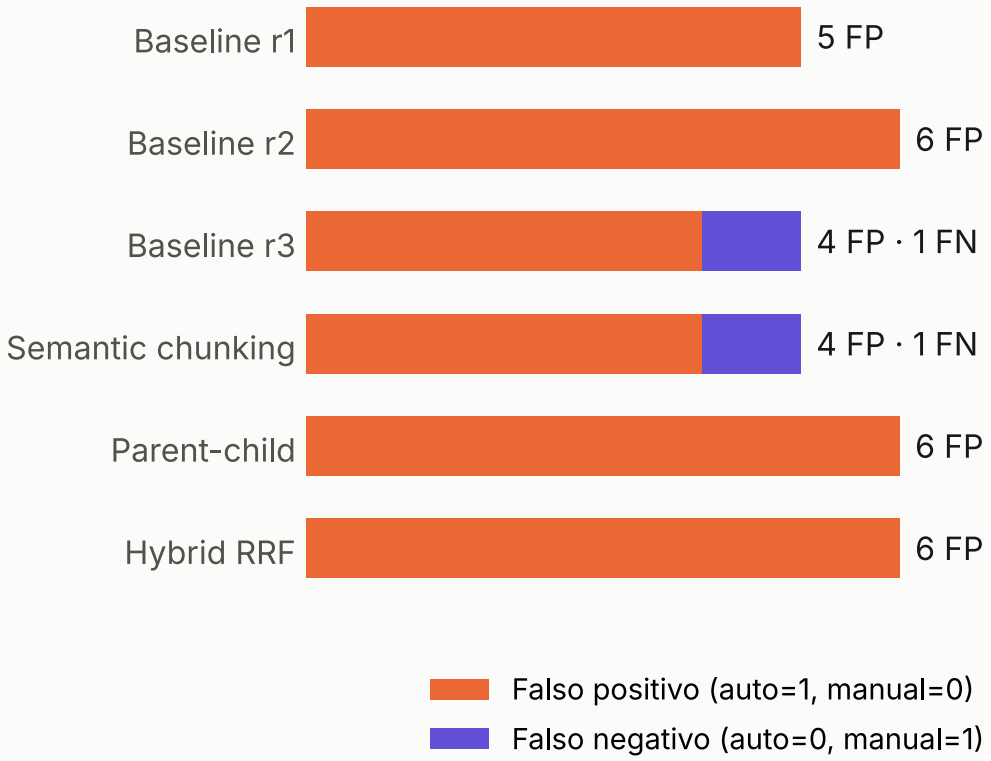
72,5% de concordância
As duas notas coincidem em 87 de 120 respostas.

Ranking parecido
Hybrid RRF é o 1º e semantic chunking o último nas duas; parent-child empata com o baseline r1 no auto, mas fica abaixo no manual.

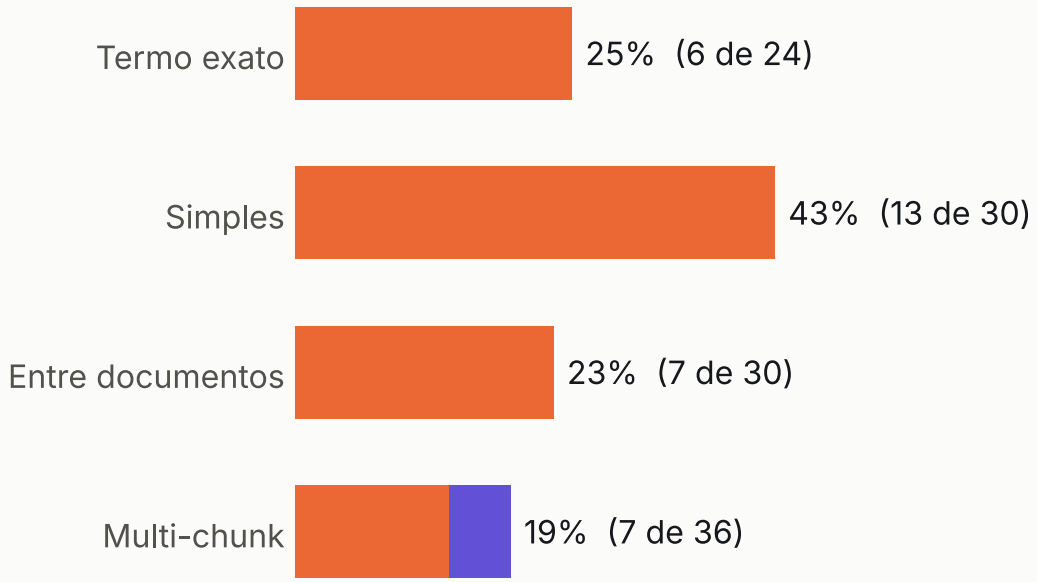
FALSOS POSITIVOS E FALSOS NEGATIVOS

Os erros do juiz são quase todos falsos positivos: 31 contra 2

Por experimento (de 20 respostas cada)



Por tipo de pergunta (% das 6 rodadas)



31 falsos positivos
36% das respostas aprovadas pelo juiz (31 de 86) estavam erradas na revisão manual.

Simples: 43% de FP
13 de 30 respostas. O juiz aprova com facilidade respostas parcialmente corretas.

2 falsos negativos
Ambos em multi-chunk (baseline r3 na pergunta 13 e semantic chunking na 12).

EXEMPLO REAL 1 · PERGUNTA 7 (TERMO EXATO)

Notas mínimas do ENEM: os 3 baselines recusam; o Hybrid RRF acerta

PERGUNTA

Quais notas mínimas no ENEM evitam a eliminação no processo seletivo de reocupação de vagas residuais?

GABARITO

Pelo menos 450 pontos em cada área de conhecimento e pelo menos 500 pontos na redação. Nota inferior a isso em qualquer uma dessas provas elimina o candidato.

Baseline r1, r2 e r3

"INFORMAÇÃO AUSENTE."

auto 0 · manual 0 nas três rodadas

`Top-6: res_013_2022 #3, #6, #4, #7, #2, #5`

Hybrid RRF

"Os candidatos que obtiverem nota inferior a 450 pontos em uma das áreas de conhecimento (...) ou nota inferior a 500 pontos na prova de redação no ENEM serão eliminados (...). Isso está descrito em Art. 14 da Resolução res_013_2022."

auto 1 · manual 1

`Top-6: res_013_2022 #6, #14, #3, #7, #12, #4`

Os trechos #14 e #12 só entram no top-6 com o Hybrid RRF; a resposta cita o Art. 14, o mesmo do gabarito. Nos demais: semantic chunking também respondeu "INFORMAÇÃO AUSENTE"; parent-child foi falso positivo (citou só os 450 pontos e omitiu os 500 da redação). Pergunta escolhida por ser a única em que as duas avaliações mostram os 3 baselines errando e o Hybrid acertando.

EXEMPLO REAL 2 · PERGUNTA 2 (TERMO EXATO)

Carga complementar: baselines erram os limites; Hybrid traz 5% a 20%

PERGUNTA

Quais são os limites mínimo e máximo da carga horária complementar de uma estrutura curricular?

GABARITO

Entre 5% e 20% da carga horária total. Em cursos com mais de 4.000 horas, a carga horária complementar mínima é de 200 horas.

Baseline r1, r2 e r3

"(...) a carga horária complementar pode variar entre 200 e 400 horas, dependendo da carga horária total do curso." (r1 e r2; a r3 repete 200 h e inclui um mínimo de 400 h)

manual 0 nas três · o juiz aprovou a r2 (falso positivo)

```
Top-6: regulamento_graduacao #18, #20, #17, #21, #224, #29
```

Hybrid RRF

"(...) a carga horária complementar não pode ser inferior a 5% ou superior a 20% da carga horária total do curso."

auto 1 · manual 1

```
Top-6: regulamento_graduacao #18, #20, #19, #17, #21, #16
```

Os trechos #19 e #16 só entram com o Hybrid RRF. A resposta do Hybrid ainda traz uma frase imprecisa sobre 200 horas em cursos com menos de 4.000 h, mas inclui os limites percentuais do gabarito, e foi aceita pelo critério manual. Para este exemplo não se afirma causa única: a mudança no top-6 e a variação do gerador atuam juntas.

Hybrid RRF foi a melhor técnica, com ganho modesto em termo exato

1. **Hybrid RRF lidera nas duas avaliações:** 55% no manual e 85% no automático, contra 48,3% e 71,7% da média do baseline. No manual, +6,7 pp (cerca de 1 pergunta).
2. **O ganho vem de termo exato:** 75% contra 25% a 50% no baseline, o que é compatível com o papel do BM25 em casar artigo, prazo e sigla.
3. **Semantic chunking e parent-child não superaram o baseline** no manual (40% e 45%). Semantic chunking foi o pior nas duas avaliações.
4. **O gargalo não é achar o documento:** o recall de documento é 100% em todos. O que falha é o trecho recuperado e a resposta gerada.
5. **Custo baixo para o Hybrid:** 1 chamada ao LLM, como os demais, e +0,5 a +0,7 s por pergunta. Parent-child custa mais (+1,3 a +1,6 s) sem ganho no manual.
6. **A avaliação automática não basta:** 31 falsos positivos em 120 respostas. Os resultados devem ser lidos pelo acerto_manual.

FECHAMENTO · LIMITAÇÕES

Com 20 perguntas e um modelo de 3B, as diferenças pedem cautela

1. **Amostra pequena:** cada pergunta vale 5 pp. O Hybrid (55%) está 1 pergunta acima da melhor rodada do baseline (50%).
2. **Ruído do gerador:** as 3 rodadas do baseline variam de 45% a 50% no manual e de 60% a 80% no automático, uma variação do mesmo tamanho que boa parte das diferenças entre técnicas.
3. **Modelo pequeno e juiz igual ao gerador:** o qwen2.5:3b gera e julga, e o juiz foi permissivo (31 falsos positivos).
4. **Métricas que saturam ou omitem:** o recall de documento é 100% em tudo e não mede o trecho certo; a contagem de chamadas ao LLM não inclui o juiz.
5. **Latência e escopo:** medida no Colab (T4) em uma passada por experimento, sensível à ordem de execução e ao estado da GPU. GraphRAG, também da família F2, não foi implementada.